

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INFORMÁTICA
CIUDAD - CHILE



“ASISTENTE DE ACCESIBILIDAD EN SITIOS WEB PARA PERSONAS CON DISCAPACIDAD VISUAL MEDIANTE EL USO DE INTELIGENCIA ARTIFICIAL”

IGNACIO BENJAMÍN RIQUELME VIDAL

MEMORIA PARA OPTAR AL TÍTULO DE
INGENIERO CIVIL EN INFORMÁTICA

Profesor Guía: Pedro Felipe Toledo Correa
Profesor Correferente: Jose Luis Martí Lara

Julio - 2026

DEDICATORIA

Considerando la importancia de este trabajo para los alumnos, este apartado es para que el autor entregue palabras personales para dedicar este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

AGRADECIMIENTOS

Considerando la importancia de este trabajo para los alumnos, este apartado se podrá incluir en el caso de que el autor desee agradecer a las personas que facilitaron alguna ayuda relevante en su trabajo para la realización de este documento. La extensión puede ser de máximo una hoja y se deben mantener este formato, tipo y tamaño de letra.

RESUMEN

Resumen— El resumen y las palabras clave no deben superar la mitad de la página, donde debe precisarse brevemente: 1) lo que el autor ha hecho, 2) cómo lo hizo (sólo si es importante detallarlo), 3) los resultados principales, 4) la relevancia de los resultados. El resumen es una representación abreviada, pero comprensiva de la memoria y debe informar sobre el objetivo, la metodología y los resultados del trabajo realizado.

- Relator: prototipo de herramienta que interpreta el contenido visual de sitios web y responde por voz a personas con discapacidad visual.
- Metodología de trabajo: encuesta -> prototipo -> benchmark -> validación con usuarios.
- Relevancia: >2.200 millones de personas con deficiencia visual; los lectores de pantalla no interpretan lo visual.

Palabras Clave— Cinco es el máximo de palabras clave para describir los temas tratados en la memoria, ponerlas separadas por punto y comas.

accesibilidad web; discapacidad visual; VLM; lectores de pantalla; benchmarking.

ABSTRACT

Abstract— Corresponde a la traducción al idioma inglés del Resumen anterior. Sujeto a la misma regla de extensión del Resumen.

Keywords— Corresponde a la traducción al idioma inglés de Palabras Clave anteriores.

GLOSARIO

Aquí se deben colocar las siglas mencionadas en el trabajo y su explicación, por orden alfabético. Por ejemplo:

DI: Departamento de Informática.

UTFSM: Universidad Técnica Federico Santa María.

ÍNDICE DE CONTENIDOS

RESUMEN	IV
ABSTRACT	IV
GLOSARIO	V
ÍNDICE DE FIGURAS	VIII
ÍNDICE DE TABLAS	VIII
INTRODUCCIÓN	1
CAPÍTULO 1: DEFINICIÓN DEL PROBLEMA	2
1.1 PROBLEMÁTICA SOCIAL	2
1.1.1 Búsqueda de antecedentes locales	3
1.1.2 La encuesta (trabajo realizado)	4
1.2 PROBLEMÁTICA TÉCNICA	5
1.3 OBJETIVOS Y ALCANCES	6
CAPÍTULO 2: MARCO CONCEPTUAL	7
2.1 LECTORES DE PANTALLA Y EL DOM	7
2.2 EXTENSIONES DE NAVEGADOR COMO CAPA INTERMEDIA	8
2.3 RECONOCIMIENTO Y SÍNTESIS DE VOZ (STT Y TTS)	9
2.4 IA MULTIMODAL: MODELOS DE LENGUAJE VISUAL (VLM)	9
2.4.1 IA generativa	9
2.4.2 IA multimodal	10
2.4.3 Inferencia en GPU	10
2.5 EVALUACIÓN AUTOMATIZADA DE VLMs	11
2.5.1 Rúbrica cualitativa	11
2.5.2 LLM-as-judge	11
2.5.3 Judge evaluation	11
CAPÍTULO 3: PROPUESTA DE SOLUCIÓN	13
EJEMPLO DE COMO CITAR FIGURAS E ILUSTRACIONES	13
3.1 ARQUITECTURA GENERAL DEL RELATOR	14
3.2 EXTENSIÓN DE CAPTURA	14
3.3 PROTOTIPO / CONTROLADOR	15
3.3.1 textToText (TTT)	15
3.3.2 textToVoice (TTV)	15
3.3.3 voiceToVoice (VTV)	15
3.4 INFRAESTRUCTURA Y SERVIDOR ALBERT	16
3.4.1 Decisión de infraestructura	16
3.5 BENCHMARK DE MODELOS VLM	17

3.5.1	Corpus y preguntas	17
3.5.2	Rúbrica de evaluación	17
3.5.3	Modelos evaluados	17
3.5.4	Pipeline y selección del juez (LLM-as-a-judge)	18
3.5.5	Resultado de la selección	18
CAPÍTULO 4: VALIDACIÓN DE LA SOLUCIÓN		19
4.1	EJEMPLO DE COMO CITAR TABLAS	19
4.2	ENFOQUE DE LA VALIDACIÓN	19
4.3	DISEÑO DEL PROCEDIMIENTO DE PRUEBA	20
4.4	MÉTRICA E INSTRUMENTO DE MEDICIÓN	20
4.4.1	Puntaje de satisfacción del usuario	20
4.4.2	Criterio de completitud	20
4.4.3	Estándar mínimo	21
4.5	EJECUCIÓN	21
4.5.1	Participantes	21
4.5.2	Sesiones	21
4.6	RESULTADOS GLOBALES	21
4.7	ANÁLISIS DE PATRONES	22
4.8	RETROALIMENTACIÓN DE LOS USUARIOS	22
4.9	CONCLUSIÓN DE LA VALIDACIÓN	22
CAPÍTULO 5: CONCLUSIONES		24
ANEXOS		25
5.1	ENCUESTA SOBRE TECNOLOGÍAS PARA PERSONAS CIEGAS	25
REFERENCIAS BIBLIOGRÁFICAS		26

ÍNDICE DE FIGURAS

1	Malla Curricular Ingeniería Civil Informática.	13
---	--	----

ÍNDICE DE TABLAS

1	Coloquios del Ciclo de Charlas Informática.	19
---	---	----

INTRODUCCIÓN

Debe proporcionar a un lector los antecedentes suficientes para poder contextualizar en general la situación tratada, a través de una descripción breve del área de trabajo y del tema particular abordado, siendo bueno especificar la naturaleza y alcance del problema; así como describir el tipo de propuesta de solución que se realiza, esbozar la metodología a ser empleada e introducir a la estructura del documento mismo de la memoria.

En el fondo, que el lector al leer la Introducción pueda tener una síntesis de cómo fue desarrollada la memoria, a diferencia del Resumen dónde se explicita más qué se hizo, no cómo se hizo.

- Área: cruce de accesibilidad web e IA (visión / VLM).
- Brecha: los lectores de pantalla no interpretan contenido visual; oportunidad de una capa intermediaria.
- Solución: el Relator como complemento, no reemplazo del lector de pantalla.
- Encuesta: punto de partida que motiva y valida el enfoque.
- Hoja de ruta: encuesta ->prototipo ->benchmark ->validación en más detalle.

CAPÍTULO 1

DEFINICIÓN DEL PROBLEMA

Se debe definir el problema, es importante no confundir definir el problema con describir la solución. Por ejemplo: “diseñar una arquitectura e implementar una plataforma ...” es una solución, no un problema.

Algunos elementos que podrían ir en este capítulo son (no es necesario que vayan todos):

- Breve descripción del contexto donde se realizará la memoria (organización, línea dentro de la Informática en la que se basa, etc.)
- ¿Qué y cómo se realiza actualmente la situación que mejorarás con tu memoria?
- ¿Qué actores o usuarios están involucrados?
- ¿Qué dificultades tienen esos actores actualmente? ¿cuántos son? (ideal si se pueden poner estadísticas para así saber si existe un mercado razonable para la solución que propondrás en tu memoria, en el fondo saber cuántas personas u organizaciones tienen el mismo problema que estás definiendo)
- ¿Qué podría pasar si en el corto o mediano plazo no se solucionan esas dificultades (¿es decir, si no se hiciera tu memoria, qué pasaría?; en el fondo justificar por qué conviene hacer tu memoria, ¿cuál es la motivación o interés de hacerla?).
- ¿Qué competencia existe actualmente? (a lo mejor ya existe una solución al problema, pero por qué no sirve, o por qué tu solución sería mejor, también se puede enfocar a si este problema existe en otras realidades y cómo ha sido solucionado allí).
- Precisar los objetivos y alcances de la memoria (o solución al problema).

En este capítulo, de ser necesario puede usar referencias bibliográficas (velar porque sean recientes), una cita de ejemplo [Schwab, 2002] y otras más [Georget *et al.*, 1994, Beaumont, 1990].

Recuerde poner notas al pie de página que sean explicativas ¹.

1.1. PROBLEMÁTICA SOCIAL

Las personas con discapacidad visual enfrentan barreras persistentes al interactuar con entornos digitales. La Organización Mundial de la Salud reporta que al menos

¹Este es un ejemplo de una nota al pie de página. Puede indicar alguna URL, definiciones, aclarar alguna información pertinente del texto, citar algunas referencias, etc..

2.200 millones de personas en el mundo tienen algún grado de deficiencia visual [World Health Organization, 2026], pero esa cifra agrupa mayoritariamente casos leves y corregibles con lentes. Al filtrar por los niveles de discapacidad relevantes para esta memoria —baja visión, discapacidad visual severa y ceguera total—, las estimaciones del Global Burden of Disease para el año 2020 son de 43,3 millones de personas ciegas y 295 millones con discapacidad visual moderada a severa, es decir, un orden de 338 millones de personas a nivel mundial [Bourne *et al.*, 2021].

Sin embargo, la magnitud de esta cifra no es lo relevante, sino la pertinencia ética de integrar a un grupo de usuarios históricamente segregado del entorno tecnológico general, en la medida en que se ve en la obligación de depender de herramientas diseñadas exclusivamente “para ciegos” en lugar de acceder al mismo contenido que el resto de los usuarios. Evitar segregar o estigmatizar a un grupo de usuarios mediante soluciones separadas ha sido, de hecho, uno de los principios formales del diseño universal —el principio de uso equitativo— en los últimos 30 años [The Center for Universal Design, 1997].

La consecuencia de no resolver estas barreras es la exclusión en las dimensiones social, laboral y educativa. La imposibilidad de acceder de forma autónoma a contenido en línea limita:

- **Social:** la participación social cotidiana.
- **Laboral:** el desempeño y las oportunidades laborales.
- **Educativo:** el acceso a instancias educativas, que involucran a un grupo más acotado.

A modo de ejemplo, hoy no es posible enterarse por cuenta propia de qué muestra una fotografía que comparte un familiar o un amigo, ni completar sin ayuda una compra o un trámite en línea cuando de por medio se exige una verificación visual [WebAIM, 2024]. Tampoco es posible darse cuenta a tiempo de un aviso que aparece de forma inesperada en la pantalla, lo que puede significar perder una oportunidad o un plazo importante. En el trabajo, muchas veces es necesario pedirle a un compañero que describa una cifra o una imagen antes de poder tomar una decisión, y postular a un empleo puede volverse una barrera en sí misma cuando el proceso exige una verificación que solo puede completarse viendo la pantalla. Algo similar ocurre en lo educativo, donde acceder a un material de estudio compartido como imagen deja a la persona a la espera de que alguien más se lo describa antes de poder seguir aprendiendo al mismo ritmo que el resto.

fuentes pendientes: confirmar y referenciar estudio(s) específicos sobre el impacto práctico de estas barreras en el ámbito laboral y educativo.

1.1.1. Búsqueda de antecedentes locales

El punto de partida se basó en que esta problemática social afecta de manera particular a las personas ciegas al navegar la web. Sin embargo, al revisar el estado del arte no se encon-

traron estudios específicos que caracterizaran con suficiente detalle esa necesidad en este grupo, sobre todo porque ya existen soluciones tecnológicas que resuelven parte de esto, como por ejemplo los lectores de pantalla ². Por ello, la problemática social se acotó hacia el contexto específico de personas con discapacidad visual que usan lector de pantalla pero aún presentan dificultades para utilizar la plenitud de la información que ofrece un sitio web al momento completar una tarea, y se diseñó y aplicó una encuesta propia con el fin de validar empíricamente la existencia y la naturaleza de la necesidad antes de proponer una solución.

1.1.2. La encuesta (trabajo realizado)

Se elaboró y distribuyó el instrumento “Encuesta sobre tecnologías para personas ciegas” mediante Google Forms, enviado por correo electrónico a miembros de la Fundación FUN-DALURP (fundación de perros guía para la rehabilitación de personas en situación de discapacidad visual). La encuesta se aplicó entre febrero y marzo de 2026 y se obtuvieron 9 respondientes. El detalle completo del instrumento —su estructura, tipos de pregunta y cómo se relacionan con la problemática— se presenta en el Anexo 5.1.

El perfil de los respondientes muestra como condición dominante la retinitis pigmentaria, con niveles de discapacidad que van desde severo hasta ceguera total, y un manejo computacional autoreportado mayoritariamente entre básico e intermedio.

Respecto de las dificultades reportadas al navegar la web con lectores de pantalla, las más frecuentes, en orden, fueron: elementos estrictamente visuales que no pueden interpretarse (imágenes, gráficos); pop-ups o notificaciones que no se leen; campos de escritura sin etiqueta; la obligación de usar el ratón para ciertas interacciones; y los captchas visuales. pendiente: agregar conteo o porcentaje exacto de respondientes que reportó cada dificultad.

En cuanto a las funcionalidades más demandadas, se destacan tres, en orden de frecuencia: describir e interpretar imágenes; la navegación por voz hacia un objetivo concreto; y la lectura de notificaciones o etiquetas dinámicas. pendiente: agregar el conteo o porcentaje exacto de respondientes que solicitó cada funcionalidad.

gráficos: distribución del perfil de respondientes (condición, nivel de discapacidad, nivel computacional) y frecuencia de dificultades y demandas reportadas.

²Programas que traducen el contenido de una página web a voz sintetizada o a un dispositivo braille; se profundiza en su funcionamiento en el Capítulo 2.

1.2. PROBLEMÁTICA TÉCNICA

Actualmente, las personas con discapacidad visual navegan la web apoyándose en lectores de pantalla, programas como JAWS, NVDA o VoiceOver que traducen el contenido de una página a voz sintetizada o a un dispositivo braille. El DOM (Document Object Model) es la estructura de nodos que el navegador construye a partir del código HTML de la página; a partir de ella, el navegador deriva un árbol de accesibilidad —una representación paralela que expone únicamente los roles, nombres accesibles, estados y relaciones relevantes para una tecnología asistiva— y lo pone a disposición a través de la API de accesibilidad del sistema operativo [MDN Web Docs, 2024a]. Es esa API la que el lector de pantalla consulta para construir lo que finalmente comunica al usuario. También existe la posibilidad de que el usuario navegue por una página utilizando únicamente el teclado, lo cual es posible gracias al atributo `tabindex` y al orden del DOM. El recorrido secuencial mediante la tecla Tab lo controla el propio navegador para la navegación por teclado, en el orden del DOM o según el atributo `tabindex`, y no es exclusivo de los lectores de pantalla ni de los usuarios con discapacidad visual.

Buena parte de la información que un lector de pantalla puede comunicar depende de las etiquetas ARIA (Accessible Rich Internet Applications): un conjunto de atributos que se agregan a los elementos del DOM para declarar roles, estados y relaciones que no tienen una etiqueta HTML nativa que los describa [MDN Web Docs, 2024b]. Por ejemplo, una notificación emergente puede marcarse como una región viva (`aria-live`) para que el lector la anuncie apenas aparece. Cuando un sitio no declara estas etiquetas, el lector de pantalla no tiene forma de identificar ese contenido dinámico, aunque técnicamente sí forme parte del DOM.

El límite de este enfoque está, entonces, en que depende por completo de que la página declare la semántica correcta —HTML nativo y ARIA— para cada elemento. Los lectores de pantalla no interpretan información estrictamente visual: no describen imágenes, gráficos ni captchas, y solo leen de forma confiable las notificaciones o pop-ups que fueron etiquetados correctamente por quien construyó el sitio. Tampoco comprenden la estructura espacial de la interfaz (qué elemento está dónde y con qué propósito) más allá del orden en que fueron declarados. El usuario recibe así una representación incompleta de la página, que depende de decisiones de accesibilidad ajenas a su control.

Respecto de la competencia y soluciones existentes, las alternativas actuales resultan insuficientes. Los lectores de pantalla, por diseño, no cubren la interpretación visual; y las soluciones basadas en IA para descripción de imágenes no están integradas al flujo de navegación ni fueron pensadas específicamente para personas ciegas, por lo que no resuelven el problema de forma completa.

tabla: comparación de soluciones existentes (lectores de pantalla, herramientas de descripción de imágenes por IA etc) frente a las capacidades requeridas, para justificar la brecha que cubre la propuesta.

fuelle pendiente: referencias recientes sobre lectores de pantalla, accesibilidad web (p. ej. WCAG) y soluciones de IA para descripción de imágenes.

1.3. OBJETIVOS Y ALCANCES

Considerando la relevancia de que las personas con discapacidad visual puedan acceder de forma equitativa a las tecnologías de la información, se plantean los siguientes objetivos para el desarrollo del asistente de accesibilidad web que en este trabajo se denomina Relator.

Objetivo general. Desarrollar el Relator, un sistema basado en inteligencia artificial capaz de analizar e interpretar la información visual de sitios web a partir de capturas de pantalla, utilizando modelos de lenguaje visual (VLM), que se integre y coexista con el lector de pantalla del usuario, con el fin de mejorar la accesibilidad de las personas con discapacidad visual.

Objetivos específicos.

- (a) Implementar un prototipo funcional del asistente (Relator) capaz de interpretar información visual y entregar descripciones auditivas.
- (b) Definir instrucciones de navegación que orienten al modelo en la interpretación de los elementos web.
- (c) Empaquetar e implementar la solución en un entorno accesible y adaptable.
- (d) Validar la solución mediante pruebas con usuarios reales con discapacidad visual.

Alcances.

Se espera que la aplicación funcione sobre navegadores basados en Chromium (Google Chrome, Microsoft Edge, Opera, entre otros) cubriendo la mayoría de los casos de uso. (Incluir cifras de uso de navegadores) El idioma de interacción contemplado es el español, aunque se espera que el modelo VLM seleccionado soporte de forma nativa otros idiomas (Esto se confirmará en Capítulo 3. Propuesta de Solución).

CAPÍTULO 2

MARCO CONCEPTUAL

Se debe describir la base conceptual o fundamentos en los que se basa tu memoria, es decir, todos los conceptos técnicos, metodologías, herramientas, etc. que están involucradas en la solución propuesta. En el fondo esta parte permite precisar y delimitar el problema, estableciendo definiciones para unificar conceptos y lenguaje y fijar relaciones con otros trabajos o soluciones encontradas por otros al mismo problema evitando así plagios o repetir errores ya conocidos o abordados por otros.

En esta parte es importante relacionar estos conceptos con la memoria y es fundamental utilizar referencias bibliográficas (o de la web) recientes, por ejemplo [Gettelfinger y Cussler, 2004].

2.1. LECTORES DE PANTALLA Y EL DOM

Un lector de pantalla es un software de tecnología asistiva que convierte el contenido de una interfaz digital —texto, controles, imágenes con texto alternativo— en voz sintetizada o en salida braille, permitiendo a una persona con discapacidad visual acceder a esa información sin necesidad de verla [Abou-Zahra y World Wide Web Consortium (W3C) Web Accessibility Initiative, 2024].

Los más difundidos son JAWS, NVDA, Windows Narrator, VoiceOver y TalkBack.

El DOM (Document Object Model) es la representación estructurada del documento web: una jerarquía de nodos (elementos, atributos, texto) que el navegador construye a partir del código HTML de la página y sobre la que se puede consultar y operar mediante programación [WHATWG, 2026]. El navegador deriva del DOM un árbol de accesibilidad, una representación paralela y más acotada que expone únicamente los roles, nombres, estados y relaciones relevantes para una tecnología asistiva, a través de la API de accesibilidad del sistema operativo (por ejemplo, UI Automation en Windows o AXAPI en macOS). Es esa API la que el lector de pantalla consulta para construir lo que finalmente comunica al usuario.

Gran parte de esa semántica no está garantizada por el HTML nativo. El W3C define para ello dos estándares complementarios: las Pautas de Accesibilidad para el Contenido Web (WCAG), que establecen los criterios que debe cumplir un sitio para considerarse accesible [Campbell *et al.*, 2024], y WAI-ARIA, un conjunto de atributos (roles, estados y propiedades `aria-*`) que permite declarar la semántica de elementos que no la tienen de forma nativa —por ejemplo, marcar una notificación emergente como una región viva (`aria-live`) para que se anuncie apenas aparece— [Nurthen *et al.*, 2023]. El atributo `alt` de HTML, por su parte, es el mecanismo nativo para asociar un texto alternativo a una imagen; sin él, una imagen no tiene ninguna representación textual que el lector de pantalla pueda comunicar

[World Wide Web Consortium (W3C), Web Accessibility Initiative, 2014].

El lector de pantalla permite al usuario recorrer **secuencialmente** los elementos interactivos de la página —cuadros de texto, menús desplegables, enlaces, botones—, uno tras otro, en el orden en que fueron declarados. Además de ese recorrido, ofrece ayudas de navegación que no existen sin él: una de las más usadas es el listado de enlaces, que presenta todos los enlaces de la página en una lista y permite saltar directamente al que se necesite.

La eficacia de este recorrido secuencial depende de la familiaridad previa del usuario con la estructura de la página: sobre un sitio ya explorado, permite ubicar rápidamente los elementos buscados; frente a un sitio nuevo, requiere recorrerlo y estudiarlo varias veces antes de poder anticipar su estructura.

tabla: lectores de pantalla más usados (JAWS, NVDA, Narrator, VoiceOver, TalkBack) y su plataforma/sistema operativo asociado.

2.2. EXTENSIONES DE NAVEGADOR COMO CAPA INTERMEDIA

Una extensión es un módulo de software que un usuario instala sobre su navegador para modificar o ampliar su comportamiento —por ejemplo, para bloquear anuncios, gestionar contraseñas o capturar información de una página—, sin ser una aplicación independiente ni una función nativa del propio navegador [MDN Web Docs, 2024c].

Google Chrome fue el primer navegador en incorporar un sistema de extensiones basado enteramente en HTML, CSS y JavaScript, habilitado en su canal de desarrollo en 2009 y lanzado de forma pública junto a Chrome 4.0 en enero de 2010 [Google Chrome Blog, 2010]. A partir de esa base, Mozilla adoptó en 2015 una API compatible para Firefox, bautizada WebExtensions, que buscaba convertirse en un estándar común entre navegadores. Aunque el intento de estandarización formal a través de un grupo de trabajo del W3C no llegó a concretarse, la popularidad de Chrome llevó a que el resto de los navegadores basados en Chromium (Edge, Opera) y, en menor medida, Firefox, convergieran hacia una API muy similar [MDN Web Docs, 2024c]. Pese a esa convergencia, las extensiones siguen siendo específicas de cada navegador: el código y el empaquetado de una extensión para Chrome no son directamente instalables en Firefox ni viceversa, aún cuando ambas compartan la mayoría de las llamadas de su API.

A nivel de capacidades, una extensión se ejecuta bajo un modelo de permisos explícitos declarados en un archivo de manifiesto: solo puede acceder a las páginas, pestañas o funciones del navegador (por ejemplo, la captura de pantalla de la pestaña activa) para las que fue autorizada, y se organiza mediante scripts de contenido —que se ejecutan en el contexto de la página visitada— y un script de fondo, que coordina la lógica de la extensión y sus comunicaciones con servicios externos. Ese modelo de permisos delimita tanto lo que la extensión puede automatizar dentro del navegador como lo que queda fuera de su alcance sin inter-

vención directa del usuario o del sistema operativo.

Su naturaleza es de dependencia parcial: la extensión necesita que exista un sitio web y un lector de pantalla para tener sentido, pero tanto el sitio como el lector funcionan igual sin ella. Es decir, la extensión se suma al flujo existente sin reemplazar ninguna de sus partes.

2.3. RECONOCIMIENTO Y SÍNTESIS DE VOZ (STT Y TTS)

Para la entrada y la salida de datos del sistema se emplean, respectivamente, el reconocimiento y la síntesis de voz.

El reconocimiento automático del habla (automatic speech recognition, ASR; también conocido como speech to text, STT) es el proceso mediante el cual un sistema decodifica una señal de audio con voz humana y la transcribe a texto, típicamente combinando un modelo acústico —que traduce la señal a una secuencia probable de fonemas— y un modelo de lenguaje —que determina, a partir de esos fonemas, las palabras más probables— [IBM, 2024b].

La síntesis de voz (text to speech, TTS) es el proceso inverso: toma una entrada textual y la convierte en audio hablado. Esa entrada no siempre es texto plano: estándares como SSML (Speech Synthesis Markup Language), del W3C, permiten anotar el texto con marcadores de énfasis, acento, velocidad o pausas, para un control más fino de cómo se pronuncia [Burnett y Shuang, 2010]. A nivel de técnica, la síntesis de voz se ha resuelto históricamente de más de una forma: por concatenación de fragmentos de voz pregrabada, por síntesis paramétrica a partir de un modelo estadístico de la voz, y, más recientemente, mediante modelos neuronales generativos que producen la forma de onda directamente a partir de datos de entrenamiento [Tan *et al.*, 2021]. Lectores de pantalla como JAWS o NVDA no necesariamente implementan su propio motor de síntesis: en general, delegan la conversión final de texto a voz a un motor TTS del sistema operativo o a una voz de terceros instalada por el usuario, y lo que le corresponde al lector de pantalla es determinar qué texto de la interfaz enviar a ese motor.

2.4. IA MULTIMODAL: MODELOS DE LENGUAJE VISUAL (VLM)

Esta subsección introduce, en términos generales, la IA generativa, la IA multimodal y los modelos de lenguaje visual (VLM).

2.4.1. IA generativa

La IA generativa es un tipo de inteligencia artificial capaz de producir contenido nuevo — texto, imágenes u otro tipo de dato— a partir de patrones aprendidos de grandes volúmenes

de datos, en lugar de limitarse a clasificar o predecir una etiqueta sobre datos ya existentes [IBM, 2024a].

En el caso particular de los modelos de lenguaje, esa generación se implementa técnicamente como una predicción. Un modelo autoregresivo, como los que se basan en la arquitectura Transformer, no produce una respuesta completa de una sola vez: predice, token a token, cuál es la unidad de texto más probable dado todo lo que ha recibido y generado hasta ese momento, y repite ese proceso hasta completar la respuesta [Vaswani *et al.*, 2017]. Es decir, “generar” contenido y “predecir la palabra siguiente” no son dos capacidades distintas, sino una relación de mecanismo a resultado: el modelo predice de forma iterativa, token a token, y esa cadena de predicciones es percibida por quien lo usa como la generación de una respuesta nueva.

2.4.2. IA multimodal

La IA multimodal corresponde a modelos capaces de procesar y/o producir información de más de un tipo de dato —texto, imágenes, audio o video— de forma conjunta, en lugar de limitarse a un único tipo de entrada o salida [Wu *et al.*, 2023]. Dentro de esa familia se encuentran los modelos de lenguaje visual (VLM, vision language model), especializados en la interacción entre texto e imágenes: reciben como entrada una combinación de imagen(es) y texto, y devuelven una salida en texto, apoyándose en una representación interna que alinea los conceptos visuales de la imagen con los conceptos del lenguaje [Wu *et al.*, 2023].

2.4.3. Inferencia en GPU

La inferencia es el acto de usar un modelo de IA ya entrenado para obtener una salida a partir de una entrada nueva, a diferencia del entrenamiento, la etapa en la que el modelo ajusta sus parámetros internos a partir de datos de ejemplo [Cloudflare, 2024]. Ejecutar esa inferencia sobre un modelo de gran tamaño es, en sí mismo, un desafío computacional: un equipo de escritorio promedio no puede hacerlo, o al menos no en tiempos aceptables. Frente a esto existen dos caminos habituales, ambos con inconvenientes: los servicios de IA en línea corren sobre datacenters de gran escala y cobran por consulta; además, procesan los datos del usuario en infraestructura de terceros, sin garantías claras sobre su tratamiento.

En este contexto aparece el concepto de latencia: el tiempo de espera entre que se envía una consulta y se recibe la respuesta. La latencia es un factor crítico para la experiencia de uso y se retoma más adelante.

tabla: comparación de alternativas de inferencia (local en equipo de escritorio / servicio en línea por consulta / equipo institucional con GPU) según costo, latencia y privacidad.

2.5. EVALUACIÓN AUTOMATIZADA DE VLMs

Existe una gran oferta de modelos VLM open source, y distintos modelos entregan resultados diferentes para las mismas consultas. Por eso se propone automatizar su evaluación.

En principio se podría tomar un VLM, hacerle N preguntas y evaluar esas N respuestas. Pero para que el resultado sea confiable se necesita un N grande, y además se quiere probar varios modelos, con lo que la evaluación manual se vuelve una tarea repetitiva e inviable a mano.

2.5.1. Rúbrica cualitativa

Para asignar puntajes se establece el concepto de rúbrica, en este caso con una escala del 0 al 3. Es una escala de puntuación cualitativa: una respuesta de nivel 0 es directamente falsa o una alucinación, mientras que una de nivel 3 es lo más cercano a lo que respondería un ser humano. Estas rúbricas deben crearse a mano de forma obligatoria.

2.5.2. LLM-as-judge

Para evaluar las respuestas de un VLM se utiliza el paradigma “LLM-as-a-judge”: un modelo LLM común (no multimodal) lee la respuesta del VLM, la compara con la rúbrica y le asigna el puntaje de forma cuantitativa, verificando si están presentes o ausentes los elementos específicos que la rúbrica exige para cada nivel.

2.5.3. Judge evaluation

Para confirmar que ese LLM evaluador funciona bien se aplica el concepto de “judge evaluation”: un humano califica las respuestas de un VLM y luego se contrasta cuánto se acercan las notas del LLM a las del humano. Es una segunda capa de evaluación, destinada a comprobar que la “regla” con la que se mide al VLM está bien graduada.

Con la judge evaluation se cierra el ciclo: el humano evalúa al LLM, el LLM evalúa al VLM, y así se valida al VLM a partir del input humano.

Respecto de los sistemas estandarizados de evaluación de VLMs, ya existen herramientas y métricas destinadas a esta tarea. Un ejemplo es VLMEvalKit (open-compass): un toolkit open source de evaluación de modelos multimodales que unifica la evaluación de una gran cantidad de modelos sobre decenas de benchmarks con configuración mínima, automatizando la preparación de datos, la inferencia y el cálculo de métricas (e incluso usando un LLM como extractor de respuestas cuando la comparación exacta falla). Sin embargo, ninguna de estas

herramientas está diseñada específicamente para la lectura de sitios web en el contexto de la discapacidad visual, que es el foco de este trabajo.

fuelle pendiente: citar VLMEvalKit (open-compass) — repositorio y paper arXiv 2407.11691. Considerar también mención a métricas generales tipo BLEURT o BERTScore como marco comparativo.

tabla/figura: esquema del pipeline de evaluación (VLM -> respuesta -> LLM-as-a-judge con rúbrica -> puntaje; y capa de judge evaluation con ground truth humano).

CAPÍTULO 3
PROPUESTA DE SOLUCIÓN

Se debe desarrollar la solución propuesta. Los subcapítulos por poner aquí son propios del autor. Se sugiere mencionar metodología usada. Es conveniente incorporar figuras y tablas para aclarar la solución, que deben indicar el número de la figura, su nombre y su autor o fuente (si las diseñas tú, la fuente es “Elaboración propia”). Ver ejemplos en esta página y en la siguiente.

Cabe mencionar que aquí está la esencia del trabajo en lo que se refiere al aporte creativo del memorista, es el momento de demostrar que usted es un destacado profesional que creó, diseñó y/o llevó a cabo la solución propuesta.

EJEMPLO DE COMO CITAR FIGURAS E ILUSTRACIONES

Se colocó una imagen que se puede referenciar también desde el texto (Ver figura 1).




Figura 1: Malla Curricular Ingeniería Civil Informática.
Fuente: Departamento de Informática.

3.1. ARQUITECTURA GENERAL DEL RELATOR

La arquitectura propuesta para el sistema se compone de una extensión de navegador y una capa controladora que coordinan la captura, el envío al modelo y la entrega de la respuesta.

La extensión de navegador se encarga de capturar la pantalla ante el input del usuario. Esa captura pasa a una capa controladora, que toma el identificador del usuario (o de la pestaña de navegador activa), la captura y la pregunta, y las envía al servidor de inferencia con GPU.

Una vez procesada, la información vuelve al controlador, que identifica a quién pertenece según el ID y devuelve el texto de respuesta al usuario correspondiente. Finalmente, ese texto es transformado a audio por el lector de pantalla del usuario. Cabe precisar que el paso de texto a voz (TTS) queda fuera del flujo de la arquitectura, ya que lo realiza el propio lector de pantalla.

En resumen, el flujo es: sitio ->extensión (captura) ->controlador (ID + captura + pregunta) ->servidor de inferencia con GPU (VLM) ->controlador (enruta según ID) ->texto de respuesta ->lector de pantalla (TTS, externo al sistema).

figura: diagrama de la arquitectura general del Relator, mostrando extensión, controlador, servidor de inferencia y la salida por el lector de pantalla. Fuente: Elaboración propia.

3.2. EXTENSIÓN DE CAPTURA

Se desarrolló una extensión diseñada para navegadores basados en Chromium, que captura el viewport visible o la página completa mediante atajos de teclado configurables por el usuario.

Para la captura de página completa se aplica una lógica de scroll & stitch: se congelan los elementos dinámicos del sitio y se aplican desplazamientos (scrolls) que permiten recorrer secuencialmente el estado actual de la página, tomando una captura en cada instante y uniéndolas luego en una sola imagen. Esto entrega la perspectiva completa y actual del sitio, según lo que requiera la consulta del usuario.

El output de las imágenes puede entregarse directamente en un formato de imagen (por ejemplo .jpg o .png) o convertirse a base64 para enviarlo más fácilmente por HTTP al controlador.

figura: esquema del scroll & stitch (congelado de elementos dinámicos, recorrido por scroll, capturas parciales y ensamblado en una imagen). Fuente: Elaboración propia.

3.3. PROTOTIPO / CONTROLADOR

El prototipo del sistema consiste en un controlador que replica la arquitectura propuesta anteriormente. Integra la captura de pantalla, la voz y el prompt, y maneja los mensajes de ida y vuelta al servidor de inferencia con GPU. También se encarga del reconocimiento de voz (STT) para las consultas del usuario.

Su naturaleza es la de una implementación funcional para validar el pipeline completo, no el producto final.

El desarrollo del prototipo se planteó en tres iteraciones, cada una funcional por sí sola:

3.3.1. textToText (TTT)

Se envía texto plano, escrito manualmente en un cuadro de input mostrado por la extensión, al modelo, y se recibe la respuesta también en texto, mostrada en un pop-up para la lectura del usuario. Esta iteración es válida solo para pruebas de desarrollador (con visión completa).

3.3.2. textToVoice (TTV)

Se envía texto plano escrito manualmente y se recibe audio de vuelta, en forma de TTS procesado por el lector de pantalla. Es la primera iteración válida para pruebas con usuarios reales.

3.3.3. voiceToVoice (VTV)

Iteración definitiva. Integra la entrada por voz vía STT —usando la Web Speech API de Google, que procesa la voz del usuario localmente o en la nube— y la salida de audio procesada por el TTS del lector de pantalla.

Las iteraciones TTV y VTV pueden convivir en el mismo software empaquetado para el usuario: queda a su criterio si prefiere escribir las preguntas o hacerlas por voz. Esta flexibilidad importa porque dejar de escribir para hablarle al computador a mitad de una sesión puede romper el flujo habitual de trabajo del usuario.

figura/tabla: comparación de las tres iteraciones (input, output, público de prueba) o capturas de la interfaz (cuadro de input y pop-up de respuesta). Fuente: Elaboración propia.

3.4. INFRAESTRUCTURA Y SERVIDOR ALBERT

La infraestructura de ejecución del proyecto contempla dos partes: los equipos de los usuarios y el servidor de inferencia con GPU.

Del lado del usuario, basta un equipo con un navegador basado en Chromium; el sistema operativo puede ser Windows, macOS, Linux o cualquiera compatible con dichos navegadores.

Para la inferencia se utilizó “albert”, una máquina del laboratorio de data science (por confirmar) que cuenta con una tarjeta gráfica NVIDIA A40 con 48 GB de VRAM, capaz de correr modelos VLM de alto nivel. Se accede a albert vía jump host desde los equipos de desarrollo para enviar las consultas mediante conexión SSH, proceso que puede automatizarse a través de un túnel SSH.

3.4.1. Decisión de infraestructura

Retomando lo planteado en el Capítulo 2 (subsección de inferencia en GPU), aquí se detalla la decisión de usar albert. Antes de optar por este servidor se probaron otras dos alternativas para ejecutar un modelo VLM acotado:

- El equipo de desarrollo local, usando la CPU (Ryzen 5 2600), ya que su GPU no cuenta con CUDA cores compatibles con los modelos evaluados.
- Los servidores de Google Colab, con el entorno de GPU NVIDIA T4 (16 GB de VRAM).

Para una misma prueba, los tiempos fueron: aproximadamente 30 minutos en la CPU Ryzen, 1 minuto en la T4 de Google Colab y tan solo 15 segundos en la A40 de albert.

Esos 15 segundos coinciden con el límite de tiempo deseado para la interacción con humanos: por encima de ese umbral se tiende a perder la atención del usuario. Este es el concepto de latencia (tiempo de espera por consulta) introducido en el Capítulo 2, ahora como requisito operativo del sistema.

fuelle pendiente: respaldar el umbral de 15 s de atención/latencia con una referencia; confirmar especificaciones exactas de albert y del equipo de desarrollo.

tabla: comparación de entornos de inferencia (Equipo local — CPU Ryzen 5 2600 / Google Colab — GPU T4 16 GB / albert — GPU A40 48 GB) con el tiempo por consulta (30 min / 1 min / 15 s). Fuente: Elaboración propia.

3.5. BENCHMARK DE MODELOS VLM

Se realizó un procedimiento de benchmarking para seleccionar el VLM más adecuado para la tarea de analizar sitios web con perspectiva de accesibilidad, evaluando sobre sitios reales.

3.5.1. Corpus y preguntas

Se armó un corpus de 10 sitios web en 4 categorías:

- Instituciones educativas: USM, UCH.
- Organizaciones estatales: SII, SENADIS.
- Sitios de e-commerce: Falabella, Mercado Libre, Ticketmaster, Ticketplus.
- Foros y comunidades: Reddit, 9gag.

Para cada categoría se escribieron 3 preguntas generales, y para cada sitio 3 preguntas específicas, sumando 6 preguntas por sitio. En total: 6 preguntas × 10 sitios = 60 preguntas por cada modelo evaluado.

3.5.2. Rúbrica de evaluación

Se escribieron rúbricas con puntajes del 0 al 3 según qué tanto se acerca la respuesta a la de un ser humano con visión completa: 0 alucinación o falsedad, 1 parcial, 2 correcta pero incompleta, 3 exacta. La rúbrica se rige por los datos literales (se debe extraer el contenido exacto de los textos; si se cambia una palabra, aunque signifique lo mismo, se considera incorrecto) y por la no verbosidad (no se mejora el puntaje de una respuesta solo por ser extensa). (tabla: rúbrica de evaluación, mostrando puntajes 0-3 y criterios de cada puntaje. Fuente: Elaboración propia.)

3.5.3. Modelos evaluados

Se parte probando con modelos pequeños, como moondream2 e InternVL2-2B, que suelen alucinar información y rara vez entregan respuestas de nivel 3. Luego se migra a modelos con más parámetros y mayor uso de GPU, como InternVL3-2B y Qwen3-VL-8B.

3.5.4. Pipeline y selección del juez (LLM-as-a-judge)

El pipeline de evaluación sigue el flujo: screenshots ->VLM ->JSON ->juez LLM ->métricas.

Para la capa de evaluación por juez se probaron distintos modelos LLM contra un set de respuestas previamente evaluadas por un humano. Se eligió como juez a Gemma3-12B (por confirmar).

Para elegir el juez se usaron métricas como el porcentaje de exact match (que el LLM asigne exactamente el mismo puntaje que el humano), que alcanzó un máximo de 72,5 % con Gemma3. También se aplicaron métricas de error tipo MAE y RMSE.

Se realizó un proceso de mejora continua de prompts para aumentar el exact match y reducir los errores del juez, iterando 20 veces hasta alcanzar el tope técnico de Gemma3. Los criterios considerados para el desarrollo del prompt de evaluación fueron: precisión espacial, razonamiento semántico y resistencia a alucinaciones.

tabla: métricas de los jueces candidatos (exact match %, MAE, RMSE) por modelo LLM evaluado. Fuente: Elaboración propia.

tabla: evolución del proceso de mejora de prompts (iteración vs. exact match / error) hasta el tope de Gemma3. Fuente: Elaboración propia.

3.5.5. Resultado de la selección

Elegido Gemma3 como juez, se corrió nuevamente el benchmark con él y se acotó la búsqueda hasta 10 modelos posibles. Dado que no se logró un exact match de 80 % o superior, se concluye que el instrumento de benchmark no es lo bastante confiable para elegir UN único mejor modelo, pero sí se acerca lo suficiente para seleccionar VARIOS de los mejores. De ese conjunto se eligió finalmente Qwen3-VL-8B.

CAPÍTULO 4

VALIDACIÓN DE LA SOLUCIÓN

Se debe validar la solución propuesta. Esto significa probar o demostrar que la solución propuesta es válida para el entorno donde fue planteada.

Tradicionalmente es una etapa crítica, pues debe comprobarse por algún medio que vuestra propuesta es básicamente válida. En el caso de un desarrollo de software es la construcción y sus pruebas; en el caso de propuestas de modelos, guías o metodologías podrían ser desde la aplicación a un caso real hasta encuestas o entrevistas con especialistas; en el caso de mejoras de procesos u optimizaciones, podría ser comparar la situación actual (previa a la memoria) con la situación final (cuando la memoria está ya implementada) en base a un conjunto cuantitativo de indicadores o criterios.

4.1. EJEMPLO DE COMO CITAR TABLAS

Se colocó una tabla que se puede referenciar también desde el texto (Ver tabla 1).

Tabla 1: Coloquios del Ciclo de Charlas Informática.
Fuente: Elaboración Propia.

Título Coloquio	Presentador, País
"Sensible, invisible, sometimes tolerant, heterogeneous, decentralized and interoperable... and we still need to assure its quality..."	Guilherme Horta Travassos, Brasil.
"Dispersed Multiphase Flow Modeling: From Environmental to Industrial Applications"	Orlando Ayala, EE.UU.
"Líneas de Producto Software Dinámicas para Sistemas atentos el Contexto"	Rafael Capilla, España.
...	...

4.2. ENFOQUE DE LA VALIDACIÓN

A fin de validar el desarrollo, se realizaron pruebas con usuarios reales con discapacidad visual sobre el sistema ya construido. Se busca medir qué tan bien el Relator resuelve tareas

reales de interpretación de imágenes en sitios web, integrando las consultas al Relator como parte del flujo de trabajo habitual del usuario con su lector de pantalla.

Dada la índole innovadora del trabajo, resulta difícil realizar una comparación cuantitativa formal —por ejemplo, contrastar los resultados de las tareas contra el lector de pantalla—, ya que los resultados esperados de uno y otro difieren demasiado entre sí. Por ello se opta por una prueba directa con el usuario, consultando su nivel de satisfacción tras completar cada tarea, llevando algo cualitativo (la sensación de satisfacción) a un valor cuantificable (un número entero).

4.3. DISEÑO DEL PROCEDIMIENTO DE PRUEBA

Se establece un número objetivo de entre 3 y 5 usuarios. Se exige que todos presenten discapacidad visual severa o ceguera total, que sean usuarios habituales de lectores de pantalla y que tengan un nivel de manejo computacional intermedio o avanzado.

Como entorno de pruebas se utiliza un subconjunto del corpus del benchmark (ver 3.5): al menos 2 sitios de categorías distintas y al menos 2 tareas por cada sitio. Además, se exige utilizar al menos una vez la modalidad por voz (VTV).

El detalle de los resultados por tarea se presenta en una tabla en el anexo. **REFERENCIA PENDIENTE: insertar ?? a la tabla del anexo correspondiente.**

4.4. MÉTRICA E INSTRUMENTO DE MEDICIÓN

4.4.1. Puntaje de satisfacción del usuario

Como se mencionó, al terminar el flujo de trabajo de cada tarea se le pregunta al usuario su nivel de satisfacción. Este es un número entero entre 1 y 5, denominado puntaje de satisfacción (PS), donde 1 corresponde a insatisfacción total (el Relator alucinó información o su respuesta fue de nula ayuda para completar la tarea), 3 a satisfacción parcial (el Relator cumplió con lo mínimo solicitado, pero hay espacio de mejora) y 5 a satisfacción total (la respuesta fue la esperada y ayudó a completar la tarea sin problemas).

4.4.2. Criterio de completitud

Se definen como tareas parciales o completadas todas aquellas que obtengan un PS mayor o igual a 3. Este criterio se comenta a los usuarios al momento de consultar su puntaje, por lo que se asume una correlación directa entre el valor entregado y la completitud de la tarea.

4.4.3. Estándar mínimo

Se considera una sesión aprobada si, sobre el total de PS, se obtiene al menos un 55 % de tareas parciales o completadas ($PS \geq 3$) y un promedio de al menos 55 %, equivalente a un PS promedio $\geq 2,75$. El estándar mínimo por sesión se extrapola a los resultados globales (sumando todas las tareas de todas las sesiones y calculando sobre el total). Por lo tanto, para validar la solución propuesta se espera obtener al menos un 55 % de tareas aprobadas y un PS promedio global mayor a 2,75.

figura: fórmula matemática para el cálculo de métricas.

4.5. EJECUCIÓN

4.5.1. Participantes

La validación se realizó finalmente con 3 participantes, dentro del rango objetivo definido. Los tres presentan ceguera total y usan JAWS como lector de pantalla. Se diferencian entre sí en las condiciones asociadas a su discapacidad visual y en su nivel de manejo computacional (uno con nivel medio y dos con nivel avanzado).

4.5.2. Sesiones

Sobre estos 3 participantes se realizaron 4 sesiones en total, ya que P2 realizó dos sesiones. De ellas, 3 se hicieron en modalidad texto (TTV) y 1 en modalidad voz (VTV).

tabla: detalle de sesiones (acá o anexo?).

4.6. RESULTADOS GLOBALES

En total se evaluaron 19 tareas a lo largo de las 4 sesiones. El promedio global de satisfacción fue de 2,84 sobre 5 (aproximadamente 56 %), y 11 de las 19 tareas (57,9 %) obtuvieron un puntaje igual o superior a 3. Estos resultados cumplen ambos umbrales definidos como estándar mínimo en la sección anterior.

tabla: resultados globales de satisfacción por tarea y sesión.

4.7. ANÁLISIS DE PATRONES

A partir de la revisión de los registros de las sesiones se identificaron patrones en el desempeño del sistema. Por categoría de sitio, el mejor desempeño se observó en sitios de e-commerce y redes sociales, mientras que el peor desempeño se dio en sitios educativos, particularmente en portales de gestión interna que requieren autenticación. Por tipo de tarea, el sistema tuvo buen desempeño en tareas descriptivas o de extracción de información –por ejemplo, “qué es”, “qué hay” o “describe”–, y un desempeño deficiente en tareas procedimentales o de navegación –por ejemplo, “cómo hago”, “dónde voy” o solicitudes de pasos a seguir–.

Entre los modos de falla identificados se cuentan: un sesgo de perspectiva vidente en las respuestas del modelo, alucinaciones cuando el elemento consultado no está visible en la captura, descripciones superficiales, y fallas del mecanismo de scroll & stitch (ver Capítulo 3, sección de extensión de captura) al capturar ventanas emergentes (no pop-ups, sino ventanas independientes usualmente para una sola función, como por ejemplo pagos online o visualizar documentos).

En la modalidad de voz se observó un comportamiento particular: se reportó una satisfacción más alta en la misma tarea ejecutada por texto incluso cuando esta no se completaba. Esto sugiere que la experiencia de interacción por voz tiene un valor intrínseco, independiente del éxito de la tarea.

4.8. RETROALIMENTACIÓN DE LOS USUARIOS

Los participantes aportaron las siguientes sugerencias de mejora durante las sesiones:

- Contar con una versión móvil y compatible con aplicaciones, no solo con navegadores de escritorio.
- Que el chat mantuviera memoria de la conversación, para poder seguir preguntando sobre un mismo elemento sin repetir contexto.
- Poder acceder o navegar directamente a un enlace ya identificado por el sistema.
- Mejorar el feedback del sistema de entrada por voz, para que el usuario sepa si lo que dice se está capturando correctamente.

4.9. CONCLUSIÓN DE LA VALIDACIÓN

Considerando que se cumplen ambos umbrales del estándar mínimo definido —un 57,9 % de tareas con puntaje igual o superior a 3, por sobre el 55 % requerido, y un promedio global

de 2,84, por sobre el mínimo de 2,75—, se declara la propuesta de solución VALIDADA.

Es necesario matizar esta conclusión: los resultados no son contundentes, sino que se ubican apenas por sobre el mínimo exigido. Los modos de falla identificados en la sección anterior y las sugerencias reportadas por los propios usuarios se abordan como trabajo futuro.

CAPÍTULO 5

CONCLUSIONES

Las Conclusiones son, según algunos especialistas, el aspecto principal de una memoria, ya que reflejan el aprendizaje final del autor del documento. En ellas se tiende a considerar los alcances y limitaciones de la propuesta de solución, establecer de forma simple y directa los resultados, discutir respecto a la validez de los objetivos formulados, identificar las principales contribuciones y aplicaciones del trabajo realizado, así como su impacto o aporte a la organización o a los actores involucrados. Otro aspecto que tiende a incluirse son recomendaciones para quienes se sientan motivados por el tema y deseen profundizarlo, o lineamientos de una futura ampliación del trabajo.

Todo esto debe sintetizarse en al menos 5 páginas.

ANEXOS

En los Anexos se incluye todo aquel material complementario que no es parte del contenido de los capítulos de la memoria, pero que permiten a un lector contar con un contenido adjunto relacionado con el tema.

5.1. ENCUESTA SOBRE TECNOLOGÍAS PARA PERSONAS CIEGAS

Este anexo detalla el instrumento mencionado en el Capítulo 1 (Definición del problema), aplicado para validar empíricamente la problemática social antes de proponer una solución.

TABLA: ficha técnica de la encuesta (nombre del instrumento, plataforma Google Forms, canal de distribución por correo electrónico a los miembros de la Fundación FUNDALURP, periodo febrero-marzo de 2026, N=9). Fuente: Elaboración propia.

La encuesta se estructuró en 4 secciones:

- PENDIENTE: nombre y contenido de la Sección 1 (perfil general del respondiente: condición, nivel de discapacidad visual, manejo computacional autoreportado).
- PENDIENTE: nombre y contenido de la Sección 2 (hábitos de uso y dificultades reportadas al navegar la web con lector de pantalla).
- PENDIENTE: nombre y contenido de la Sección 3 (preguntas generales sobre necesidades y funcionalidades de accesibilidad demandadas).
- PENDIENTE: nombre y contenido de la Sección 4 (preguntas específicas por tipo de sitio web).

PENDIENTE: detallar la diferencia entre las preguntas de tipo general (aplicadas a todos los respondientes) y las preguntas específicas (según el tipo de sitio web consultado), con ejemplos concretos de cada una.

REFERENCIAS BIBLIOGRÁFICAS

- [Abou-Zahra y World Wide Web Consortium (W3C) Web Accessibility Initiative, 2024] Abou-Zahra, S. y World Wide Web Consortium (W3C) Web Accessibility Initiative (2024). Tools and techniques. <https://www.w3.org/WAI/people-use-web/tools-techniques/>. Actualizada el 25 de junio de 2024.
- [Beaumont, 1990] Beaumont, R. H. (1990). Patient preference for waxed or unwaxed dental floss. *Journal of periodontology*, 61(2):123–125.
- [Bourne *et al.*, 2021] Bourne, R. R. A., Steinmetz, J. D., y Flaxman, S. (2021). Trends in prevalence of blindness and distance and near vision impairment over 30 years: an analysis for the global burden of disease study. *The Lancet Global Health*, 9(2):e130–e143. **Lista de autores truncada (GBD Vision Loss Expert Group, +150 colaboradores); confirmar formato de cita abreviada antes de la entrega final.**
- [Burnett y Shuang, 2010] Burnett, D. C. y Shuang, Z. W. (2010). Speech synthesis markup language (ssml) version 1.1. Technical report, World Wide Web Consortium. W3C Recommendation, 7 de septiembre de 2010.
- [Campbell *et al.*, 2024] Campbell, A., Adams, C., Montgomery, R. B., Cooper, M., y Kirkpatrick, A. (2024). Web content accessibility guidelines (wcag) 2.2. Technical report, World Wide Web Consortium. W3C Recommendation, 12 de diciembre de 2024.
- [Cloudflare, 2024] Cloudflare (2024). Ai inference vs. training: What is ai inference? <https://www.cloudflare.com/learning/ai/inference-vs-training/>.
- [Georget *et al.*, 1994] Georget, D., Parker, R., y Smith, A. (1994). A study of the effects of water content on the compaction behaviour of breakfast cereal flakes. *Powder Technology*, 81(2):189–195.
- [Gettelfinger y Cussler, 2004] Gettelfinger, B. y Cussler, E. (2004). Will humans swim faster or slower in syrup? *AIChE journal*, 50(11):2646–2647.
- [Google Chrome Blog, 2010] Google Chrome Blog (2010). Chrome extensions and the chrome web store: 2009–2010. <https://chrome.googleblog.com/2010/>. **Confirmar entrada específica del blog o reemplazar por developer.chrome.com antes de la entrega final.**
- [IBM, 2024a] IBM (2024a). Generative ai vs. predictive ai: What's the difference? <https://www.ibm.com/think/topics/generative-ai-vs-predictive-ai-whats-the-difference>.
- [IBM, 2024b] IBM (2024b). What is speech recognition? <https://www.ibm.com/think/topics/speech-recognition>.

- [MDN Web Docs, 2024a] MDN Web Docs (2024a). Accessibility tree. https://developer.mozilla.org/en-US/docs/Glossary/Accessibility_tree.
- [MDN Web Docs, 2024b] MDN Web Docs (2024b). Aria. <https://developer.mozilla.org/en-US/docs/Web/Accessibility/ARIA>.
- [MDN Web Docs, 2024c] MDN Web Docs (2024c). Webextensions. <https://developer.mozilla.org/en-US/docs/Mozilla/Add-ons/WebExtensions>.
- [Nurthen *et al.*, 2023] Nurthen, J., Cooper, M., y Henry, S. L. (2023). Wai-aria 1.2. Technical report, World Wide Web Consortium (W3C). W3C Recommendation, 6 de junio de 2023.
- [Schwab, 2002] Schwab, I. R. (2002). Cure for a headache. *British Journal of Ophthalmology*, 86(8):843–843.
- [Tan *et al.*, 2021] Tan, X., Qin, T., Soong, F., y Liu, T.-Y. (2021). A survey on neural speech synthesis. *arXiv preprint arXiv:2106.15561*.
- [The Center for Universal Design, 1997] The Center for Universal Design (1997). The principles of universal design, version 2.0. Technical report, North Carolina State University. **Confirmar URL estable de la fuente primaria de NCSU antes de la entrega final.**
- [Vaswani *et al.*, 2017] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., y Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems*, volumen 30.
- [WebAIM, 2024] WebAIM (2024). Screen reader user survey #10 results. <https://webaim.org/projects/screenreadersurvey10/>.
- [WHATWG, 2026] WHATWG (2026). Dom standard. <https://dom.spec.whatwg.org/>. Living Standard.
- [World Health Organization, 2026] World Health Organization (2026). Blindness and vision impairment. <https://www.who.int/news-room/fact-sheets/detail/blindness-and-visual-impairment>. Fact sheet, actualizada el 10 de febrero de 2026.
- [World Wide Web Consortium (W3C), Web Accessibility Initiative, 2014] World Wide Web Consortium (W3C), Web Accessibility Initiative (2014). Resources on alternative text for images. <https://www.w3.org/WAI/alt/>.
- [Wu *et al.*, 2023] Wu, J., Gan, W., Chen, Z., Wan, S., y Yu, P. S. (2023). Multimodal large language models: A survey. *arXiv preprint arXiv:2311.13165*.